

공개 대학 교육자료 기반 1:1 맞춤형 에이전트 튜터링 모바일 시스템 아키텍처 및 서비스 전략

1. 공개 고등교육 자원(OER) 생태계와 법적·기술적 연동 규제

전 세계 고등교육 기관의 지식 자산을 공공재로 환원하려는 오픈 교육 리소스(Open Educational Resources, OER) 운동은 2000년대 초 매사추세츠 공과대학교(MIT)의 OpenCourseWare(OCW) 프로젝트를 기점으로 본격화되었다. 이후 대규모 개방형 온라인 강좌인 MOOC(Massive Open Online Courses)로 진화하면서 고등교육의 물리적 장벽을 대폭 낮추었으나, 일방향적 지식 전달 구조로 인해 완주율이 저조하다는 구조적 한계를 노출해 왔다. 생성형 인공지능(GenAI) 기반의 에이전트 시스템은 이러한 오픈 코스웨어 자원을 개별 학습자의 인지 수준에 맞춰 재구성할 수 있는 핵심 동력으로 주목받고 있다. 그러나 상용 서비스 환경에서 공개 강의 자료를 안정적으로 연동하고 가공하기 위해서는 각 플랫폼의 기술적 접근 규격과 엄격한 법적 라이선스 장벽을 사전에 정밀하게 검토해야 한다.

1.1 국내외 오픈 코스웨어 데이터 연동 규격 및 접근 경로

국내 대표 플랫폼인 K-MOOC는 국가평생교육진흥원이 총괄 관리하며, 공공데이터포털(data.go.kr)의 오픈 API(국가평생교육진흥원_K-MOOC 강좌정보API)를 통해 강좌 식별자, 개설 대학, 교수자 정보, 주차별 강의 구성, 학습 인정 시간, 공식 스트리밍 엔드포인트 URL을 JSON 및 XML 포맷으로 제공한다. 반면 한국교육학술정보원(KERIS)이 주관하는 KOCW(Korea Open CourseWare)는 전국 주요 대학의 정규 강의계획서, 강의 녹화물, 강의 교재(PDF, PPT)를 수집하여 통합 검색 및 데이터베이스 연계를 지원한다. 해외의 경우 MIT OCW가 공식 포털 및 개방형 클라우드 저장소(AWS Open Data S3), 공개 리포지토리를 통해 강의 실라버스, 렉처 노트, 시험 문항, 비디오 자막 파일(VTT, SRT) 등 전 과정 자료를 정적 자료로 배포하고 있다. 이러한 플랫폼들은 공통적으로 고등교육의 보편적 확산을 지향하지만, 데이터 배포 아키텍처와 연동 인터페이스의 성격에 따라 서비스 구현 전략을 차별화해야 한다.

| 플랫폼명 | 주관 기관 및 대학 | 핵심 제공 데이터 형식 | 메타데이터 연동 방식 | 기본 라이선스 규정 || :--- | :--- | :--- | :--- | :--- || **K-MOOC** | 국가평생교육진흥원 | 주차별 강좌, 동영상, 퀴즈, 강의계획서 | 공공데이터포털 Open API (JSON/XML) | 강좌별 상이 (통상 공공누리 및 비영리 조건 부과) || **KOCW** | 한국교육학술정보원(KERIS) | 강의계획서, 비디오 녹화본, PPT/PDF 교재 | 교육 학술 정보 연계 API 및 웹 검색 포털 | 크리에이티브 커먼즈(CC BY-NC-ND/SA 위주) || **MIT OCW** | 매사추세츠 공과대학교 | 강의 노트, 시험지, 자막(VTT/SRT), 영상 | 정적 CDN, GitHub 리포지토리, AWS S3 | Creative Commons BY-NC-SA |

1.2 지식재산권 한계와 합법적 서비스 연동 아키텍처

MIT OCW를 비롯한 글로벌 오픈 코스웨어의 지배적 라이선스는 CC BY-NC-SA(저작자표시-비영리-동일조건변경허락)이다. 이 규정은 원본 교육 자료의 상업적

판매를 원천 금지할 뿐만 아니라, 해당 자료를 가공하여 제작한 2차적 저작물(Derivative Works)로부터 직접적인 수익을 창출하는 행위 역시 불허한다. 나아가 MIT OCW의 최신 이용약관은 OCW 자원을 학습 데이터셋으로 활용하여 구축한 인공지능 모델의 상업적 운용까지 제한하고 있어 단순 파인튜닝 방식의 모델 상용화에 법적 제약을 부과한다. 국내 저작권법 환경 역시 엄격한 기준을 적용한다. 저작권법 제25조(학교교육 목적 등의 이용)는 교육기관이 수업 목적상 필요한 경우 공표된 저작물을 복제·전송할 수 있도록 명시하고 있으나, 이는 초·중·고교 및 대학교와 같은 정규 교육기관의 직접 수업 과정에 한정된다. 따라서 영리 법인이 운영하는 모바일 에듀테크 서비스는 제25조의 적용을 받을 수 없으며, 저작권법 제35조의3(저작물의 공정한 이용) 요건을 충족해야 한다. 공정이용 성립 여부를 판단할 때는 이용의 영리성 여부, 원저작물에서 인용된 부분이 차지하는 비중과 질적 중요성, 그리고 해당 이용이 원저작물의 시장 가치나 잠재적 수요를 대체하는지 여부가 종합적으로 고려된다. 판례는 상업적 플랫폼이 타인의 저작권 침해 영상을 무단 인라인 링크하거나 영상 스트림을 직접 복제하여 서비스의 주요 수익 기반으로 활용할 경우 저작권 침해 방조 책임을 인정하고 있다.

이러한 법적 리스크를 원천적으로 차단하기 위해 본 모바일 튜터링 서비스는 비디오 원본 파일을 자체 서버에 저장·재전송하지 않는 무저장(Stateless) 프록시 및 임베딩 연동 아키텍처를 채택해야 한다. 비디오 재생은 K-MOOC API 또는 YouTube 공식 Iframe 플레이어를 인앱 웹뷰 형태로 임베드하여 원저작권자의 트래픽과 플랫폼 지표가 보존되도록 구성한다. 동시에 서비스의 과금 모델을 '강의 콘텐츠 판매'가 아닌 '개인화된 학습 경로 설계 및 실시간 대화형 추론 엔진 이용권'으로 정의하는 BYOC(Bring Your Own Content)형 인프라 SaaS 전략을 취함으로써 저작권법상 비영리 제한 조항과의 마찰을 회피할 수 있다.

2. 멀티모달 강의 데이터 처리 파이프라인 및 교육용 지식 베이스 구축

대학 강의는 1회당 60분에서 90분에 달하는 장시간 동영상 내에 구술 해설, 칠판 판서, 슬라이드 발표 자료, 다이어그램, 복잡한 수식이 뒤섞여 있는 고밀도 비구조화 데이터다. 튜터링 에이전트가 이를 정확한 학술적 근거로 활용하기 위해서는 음성과 시각 정보를 정밀하게 분할하고 구조화하는 멀티모달 데이터 엔지니어링이 선행되어야 한다.

2.1 시청각 강의 분할 및 비전-언어 인덱싱 파이프라인

강의 영상의 오디오 스트림은 faster-whisper의 large-v3-turbo 파이프라인을 통해 처리된다. CTranslate2 기반 추론 가속 엔진과 FP16 정밀도를 결합하여 표준 Whisper 모델 대비 약 4배의 처리 속도를 달성하며, 모든 발화 단위에 대해 밀리초 단위의 단어 수준 타임스탬프(Word-level Timestamps)를 추출한다.

비디오 스트림에서는 균일 시간 분할 방식의 맥락 단절 문제를 극복하기 위해 적응형 청킹(Adaptive Chunking) 기법을 적용한다. 인접 프레임 간의 CLIP 임베딩 코사인 유사도와 구조적 유사도 지수(SSIM)를 결합하여 슬라이드가 전환되는 경계 시점을 감지하고, 분할된 구간 내에서 시각 정보 엔트로피가 극대화되는 시점을 대표 키프레임으로 추출한다. 슬라이드 문서와 강의 교재 PDF의 인덱싱에는 비전-언어 모델 기반의 레이트 인터랙션(Late Interaction) 검색 모델인 ColPali 또는 ColQwen2.5를 도입한다. 종래의 광학 문자 인식(OCR) 방식은 다단 학술 논문, 2차원 표, 복잡한 미적분 수식을 1차원 문자열로 강제 평탄화하면서 구조적 의미를 상실시키는 한계가 있었다. ColPali 아키텍처는 문서 이미지를 시각 패치 토큰 다중 벡터($D = \{d_1, d_2, \dots, d_{|D|}\}$)로 투영한 후 질의어 토큰 벡터($Q = \{q_1, q_2, \dots, q_{|Q|}\}$)와 토큰 간 최대 유사도를 계산하는 MaxSim 연산을 수행한다: $S(Q, D) = \sum_{i=1}^{|Q|} \max_{j=1}^{|D|} \left(\frac{q_i \cdot d_j}{\dots} \right)$

$d_j \setminus \text{q}_i \setminus d_j \setminus \text{right}$

이 연산을 통해 OCR 변환 오차를 완전히 배제하고, 수식과 도표가 배치된 시각적 레이아웃 전체를 보존한 채 고밀도 의미 검색을 수행할 수 있다. 검색된 시각 패치와 음성 전사 세그먼트는 타임스탬프를 매개로 상호 결합되어 다차원 검색 인덱스를 형성한다.

처리 계층	핵심 적용 기술	입력 데이터	산출물 및 엔지니어링 특성
음성 전사 계층	faster-whisper (large-v3-turbo)	강의 오디오 트랙 (AAC/MP3)	단어 단위 타임스탬프가 포함된 전사 세그먼트
슬라이드 분할 계층	CLIP 임베딩 + SSIM 적응형 세그멘테이션	강의 비디오 스트림 (H.264)	슬라이드 전환 타임스탬프 및 최대 엔트로피 키프레임
시각 문서 인덱싱	ColQwen2 [span_80](start_span)[span_80](end_span).5 / ColPali	슬라이드 키프레임 및 원본 강의 교재	패치 단위 다중 벡터 (Late Interaction MaxSim 검색 지원)
시공간 정렬 계층	Temporal-Visual Cross Aligner	전사 텍스트 + 키프레임 이미지	시간 구간 $[t_{\text{start}}, t_{\text{end}}]$ 기반 멀티모달 교육 청크

2.2 교육용 온톨로지 설계 및 선수학습(Prerequisite) 관계 추론

파편화된 멀티모달 청크들을 지식 체계로 조직화하기 위해 도메인 온톨로지 기반의 교육용 지식 그래프(EduKG)를 구축한다. 온톨로지는 학문적 상위 개념과 하위 범주를 정의하는 도메인 모델(Domain Model), 강좌, 주차, 세션, 토픽, 하위 토픽으로 이어지는 커리큘럼 모델(Curriculum Model), 그리고 학습자의 인지 상태와 시험 성취도를 추적하는 학습자 모델(User Model)의 세 가지 축으로 정형화된다.

개인화된 커리큘럼 생성의 핵심은 지식 노드 간의 선수학습 관계(Prerequisite Relationships, PR)를 규명하는 것이다. 개념 A의 습득이 개념 B를 이해하기 위한 필수 요건($A \prec B$)인지 판별하기 위해, 강의 계획서의 출현 순서, 위키백과 하이퍼링크 참조 계층, 지식 그래프 토폴로지 중심성, 거대언어모델(LLM) 기반 개념 의존성 검증을 결합한 다기준 투표(Multi-criteria voting) 알고리즘을 적용한다. 도출된 의존 관계는 유향 비순환 그래프(Directed Acyclic Graph, DAG) 구조로 결합되어, 선수 지식 결손을 방지하면서도 비선형적인 우회 학습 경로를 유연하게 생성할 수 있는 지식 기반을 제공한다.

3. 맞춤형 커리큘럼 기획 에이전트와 계층적 다중 에이전트 오케스트레이션

단일 LLM 호출을 통한 커리큘럼 기획은 장기적 맥락 유지의 불안정성, 세부 학습 목표 누락, 선수 과목 의존성 훼손 등의 한계를 가진다. 따라서 다중 에이전트 시스템(Multi-Agent System, MAS) 기반의 분할-정복 계층 계획(Hierarchical Planning) 프레임워크가 필수적이다.

3.1 에이전트 지향 계획(AOP)과 피드백 루프

시스템의 최상위 계층에 위치한 메타 플래너(Meta-Agent)는 학습자의 최종 목표를 접수한 후, 이를 해결 가능한 세부 학습 과제들로 분해하여 전문 하위 에이전트들에게 배분한다. 이때 계획의 유효성을 보장하기 위해 세 가지 기본 원칙이 강제된다. 첫째, 분해된 모든 하위 과제는 도메인 매핑 에이전트나 난이도 평가 에이전트 등 단일 에이전트의 역량 범위 내에서 완결될 수

있어야 한다는 해결 가능성(**Solvability**)이다. 둘째, 하위 과제들의 논리적 합이 사용자의 초기 학습 목표를 완전히 포괄해야 한다는 완전성(**Completeness**)이다. 셋째, 한정된 학습 시간을 최적화하기 위해 불필요한 중복 개념 학습을 철저히 배제하는 비중복성(**Non-redundancy**)이다. 생성된 초기 학습 계획은 계획 검증기(**Plan Detector**)와 보상 모델(**Reward Model**)의 검증 단계를 거친다. 계획 검증기는 세부 과제 간의 논리적 누락이나 중복을 필터링하며, 보상 모델은 과제 임베딩과 에이전트 프로필 임베딩을 결합 분석하여 계획의 정밀성, 적합성, 논리적 타당성을 수치화한다. 만약 산출된 보상 점수가 사전 정의된 기준치에 미달할 경우 계획은 즉각 메타 플래너로 피드백되어 재조정 루프를 순환함으로써 커리큘럼의 실행 가능성을 담보한다.

3.2 온보딩 진단 평가와 실시간 동적 커리큘럼 재구성

개인 맞춤형 경로를 가동하기 위해 시스템은 온보딩 단계에서 **3~5**문항의 개념 진단 평가를 실시하여 학습자 모델의 지식 파라미터를 초기화한다. 진단 결과는 **EduKG**의 세부 노드에 투영되어 학습자의 기보유 역량과 결손 지점을 시각화한다. 초기 커리큘럼이 확정된 이후에도 시스템은 고정된 일정을 강요하지 않고 실시간 학습 세션 데이터를 모니터링한다. 학습자가 특정 강의 구간을 반복 시청하거나 형성평가 퀴즈에서 오답을 기록하는 경우, 시스템은 **DAG** 그래프의 역방향 탐색을 수행하여 해당 개념의 직접적인 선수 지식 결손 여부를 진단한다. 만약 상위 개념 이해 실패의 원인이 하위 선수 개념의 부재로 판명되면, 메타 플래너는 **3**분 내외의 마이크로 선수 강의 클립과 확인 문항을 기존 커리큘럼 사이에 동적으로 삽입하여 인지적 결손을 즉각 해소한다.

4. 대화형 튜터링 상호작용 엔진과 학술적 신뢰성 보장 메커니즘

인공지능 튜터링 서비스가 지닌 가장 중대한 결함은 학습자에게 완제품 형태의 정답을 성급하게 제공하여 인지적 사고 과정을 차단하는 현상과, 학술적 엄밀성을 저해하는 환각(**Hallucination**) 현상이다.

4.1 소크라테스식 문답법(**Socratic Scaffolding**) 프롬프트 엔지니어링

학습자의 주도적 문제 해결 역량을 촉진하기 위해 시스템은 정답을 직접 진술하지 않고 유도 질문을 통해 단계적으로 해답에 도달하도록 이끄는 소크라테스식 튜터링 설계를 채택한다. 튜터 에이전트는 학습자가 직면한 병목 지점을 특정하고, 복잡한 개념을 최소 단위의 논리적 명제로 분해한 후 한 턴에 오직 하나의 유도 질문만을 제시한다.

무분별한 힌트 의존을 방지하기 위해 엄격한 **3단계 에스컬레이션 정책(3-step escalation policy)**을 프롬프트 시스템에 통합한다. 학습자가 자체적인 사고 노력 없이 연속 **2**회 이상 단순 힌트나 정답을 요구할 경우 구조적 유추 단서만을 제한적으로 제공하며, **3**회 연속으로 유의미한 시도 없이 답변을 요구할 때는 힌트 제공을 중단하고 바로 전 단계의 안내 단서를 스스로 설명하도록 강제하여 메타인지적 반추를 유도한다. 나아가 수학, 공학, 물리 등 수식 검증이 요구되는 도메인에서는 거대언어모델의 언어적 직관에 의존하지 않고, 내부 **Python** 환경의 **SymPy** 기호 연산 엔진을 툴 호출(**Tool Calling**)하여 학생의 중간 유도식과 최종 계산을 기호적으로 검증한 후 언어적 피드백을 출력하도록 통제한다.

[소크라테스식 튜터 에이전트 시스템 지침] 귀하는 격려와 학술적 엄밀성을 동시에 견지하는 교육 튜터이다. 어떠한 경우에도 최종 정답, 완성된 공식, 문제 풀이 전체를 직접 제공하지 말라. 학습자가 혼란을 겪는 세부 개념을 파악하고, 문제를 논리적 단위로 분해하여 사고를 유도하는 질문을 한 번에 하나씩만 제시하라. 학습자가 능동적 시도 없이 힌트만을 지속 요구할 경우 점진적으로 비계를 축소하고 직전 단서에 대한 학습자의 해석을 역질문하라. 수학적 전개

및 기호 수식이 포함된 모든 피드백은 반드시 내부 **SymPy** 연산 검증을 거친 후 출력해야 한다.

4.2 Corrective RAG 및 시공간 근거 표기 기반 환각 억제

학술적 정확도를 확보하기 위해 **Corrective RAG(CRAG)** 검색 검증 프레임워크를 적용한다. 에이전트가 생성하는 모든 교육적 해설은 검색된 강의 전사 텍스트의 타임스탬프([MM:SS]) 및 공식 슬라이드 페이지 번호를 필수 인용 메타데이터로 첨부하도록 강제한다. 만약 학습자의 질문에 대응하는 지식 베이스 검색 청크의 의미 유사도가 사전 설정된 신뢰도 임계값($\tau < 0.65$)에 미치지 못하거나 강의 범위 밖의 내용을 질의받은 경우, 언어모델이 불확실한 정보를 임의로 추론하지 못하도록 통제한다. 이 경우 에이전트는 해당 내용이 현재 등록된 강의의 범위를 벗어났음을 명확히 밝히고, 관련 대학 공개 강의의 보충 링크를 안내하거나 담당 교수자의 공식 **Q&A** 포럼으로 연계하는 안전한 폴백(**Safe Fallback**) 메커니즘을 가동하여 학술적 신뢰성을 유지한다.

5. 생성형 AI 교육 서비스 벤치마킹 및 모바일 인터랙션 UX 설계

5.1 상용 AI 에듀테크 서비스 비교 분석

글로벌 교육 시장에서 생성형 AI를 선도적으로 결합한 서비스들은 각기 다른 상호작용 철학과 기술 구조를 바탕으로 학습 가치를 창출하고 있다. 칸아카데미의 **Khanmigo**는 소크라테스식 문답법과 교육과정 연계에 집중하고 있으며, 듀오링고의 **Duolingo Max**는 오답 원인을 문법적으로 해체해 주는 **Explain My Answer**와 생성형 롤플레이팅 기능을 결합하였다. 한편 스피크(**Speak**)는 저지연 음성 대화 파이프라인을 중심으로 발화 중심의 언어 훈련에 특화되어 있다.

| 서비스명 | 개발 기관 | 핵심 기술 및 AI 아키텍처 | 주요 UI/UX 인터랙션 모델 | 비즈니스 모델 및 시장 전략 || :--- | :--- | :--- | :--- | :--- || **Khanmigo** | 칸아카데미 | 소크라테스식 문답, 기호 연산 도구 연동, 힌트 에스컬레이션 제어 | 웹 기반 문제 풀이 화면 내 우측 대화형 사이드 패널 | 공공 기부금 및 B2B 공립 교육구(District) 파트너십 || **Duolingo Max** | 듀오링고 | GPT-4 기반 **Explain My Answer**, 대화형 **Roleplay** 시뮬레이션 | 문제 풀이 세션 내 즉각형 오답 해설 모달 및 캐릭터 채팅 | 프리미엄 상위 티어 구독제 (ARPU 상승 견인) || **Speak** | 스피크이저랩스 | 실시간 음성 상호작용 엔진, WebRTC 오디오 파이프라인 | 전면 음성 통화 UI, Learn-Practice-Apply 3단계 루프 | B2C 정기 구독제, OpenAI Realtime API 결합 || 본 제안 서비스 | - | 다중 에이전트 커리큘럼 계획, 멀티모달 RAG(ColPali+Whisper), FSRS 스케줄러 | 2분할 반응형 캔버스 (상단 공식 미디어 + 하단 튜터 패널) | BYOC형 AI 연산 구독 모델, 공공 OCW 메타데이터 연동 |

5.2 모바일 화면 최적화를 위한 2분할 캔버스 레이아웃

화면 면적이 제한적인 모바일 기기에서 장시간의 대학 강의 영상과 고밀도 학술 대화를 동시에 소화하기 위해서는 인지 부하를 최소화하는 인터페이스 구조가 요구된다. 본 서비스는 미디어와 텍스트 대화창의 상호작용 맥락을 보존하는 2분할 캔버스(**Two-pane Canvas**) 설계를 도입한다.

화면 상단 영역에는 16:9 비율의 공식 동영상 플레이어와 ColPali 기반의 슬라이드 시각 자료가 고정 배치된다. AI 튜터가 설명 과정에서 특정 개념을 언급할 경우, 플레이어의 타임라인은 해당 발화 지점으로 원터치 동기화(**Deep-linking**)되어 학습자가 즉각 시청각 맥락을 재확인할

수 있도록 지원한다. 화면 하단 영역에는 소크라테스식 튜터링 패널이 배치되며, 에이전트의 내부 계획 및 추론 과정(Thinking Traces)은 기본적으로 간소화된 요약 형태로 접혀(Collapsed) 표시되어 학습자의 주의 집중을 방해하지 않는다. 학습자는 중앙의 드래그 핸들러를 조작하여 강의 중심 시청 시 미디어 뷰포트를 70%로 확대하거나, 집중 문답 시 대화 패널을 70%로 확장하는 유연한 화면 구성을 선택할 수 있다.

6. 인지과학 기반 망각 방지 학습 관리 시스템(LMS)과 동기 부여 체계

고등교육 콘텐츠의 방대한 분량과 높은 난이도는 독학 환경에서 심각한 중도 포기를 유발한다. 지속적인 학습 유지를 위해서는 인지과학적으로 검증된 간격 반복(Spaced Repetition) 알고리즘과 정교한 마이크로러닝 설계가 뒷받침되어야 한다.

6.1 DSR 기반 FSRS(Free Spaced Repetition Scheduler) 알고리즘 통합

초기 암기 소프트웨어에서 널리 쓰이던 SM-2 알고리즘은 사용자의 주관적인 체감 난이도 평가에 의존하며 고정된 승수를 사용하여 비효율적인 복습 일정을 생성하는 한계가 있었다. 본 시스템은 난이도(Difficulty, D), 안정성(Stability, S), 인출 확률(Retrievability, R)의 3변수를 수학적으로 추적하는 현대적 머신러닝 스케줄러인 FSRS를 LMS 엔진으로 통합한다.

FSRS는 인간 기억의 인출 확률 $R(t)$ 를 단순 지수함수가 아닌 실제 대규모 학습 로그에 부합하는 멱함수(Power Law) 모델로 정식화한다:

$$R(t) = \left(1 + F \cdot \frac{t}{S} \right)^{-C}$$

여기서 t 는 직전 복습 이후 경과된 일수이며, S 는 기억의 파지율이 목표 수준까지 유지되는 기간(일 단위), F 와 C 는 개별 학습자의 망각 패턴에 맞춰 최적화되는 형상 모수이다. 시스템은 난이도(D)와 안정성(S)을 학습자의 실제 형성평가 정오답 데이터로부터 기계학습 모델을 통해 역산한다.

학습자가 목표 파지율(Target Retention Rate, 통상 90%)을 지정하면, FSRS는 기억의 인출 확률이 0.90으로 떨어지는 정밀한 시점을 예측하여 복습 퀴즈를 자동 배정한다. 이를 통해 기존 알고리즘 대비 학습자의 복습 횟수를 20%에서 30%가량 절감하면서도 동일한 지식 파지 수준을 안정적으로 달성할 수 있다.

6.2 마이크로러닝 루프와 상태 기반 동기 부여 설계

대학의 75분 정규 강의는 모바일 환경에 적합하도록 5분에서 10분 단위의 원자적 개념 단위(Atomic Concept Units)로 분해된다. 각 단위는 핵심 동영상 클립 시청(3분), 소크라테스식 핵심 확인 질문(2분), FSRS 기반 형성평가 플래시 퀴즈(2문항, 2분), 그리고 튜터 피드백 및 요약 카드 수령(3분)으로 구성되는 10분 마이크로 루프로 완결된다.

학습 지속성을 높이기 위해 듀오링고의 연속 학습 스트릭(Streak) 체계를 모바일 경험에 통합한다. 이때 푸시 알림은 무작위 시간에 일괄 발송되는 방식이 아니라, FSRS 엔진상에서 주요 개념 노드의 인출 확률이 망각 임계선 이하로 진입하는 시점에 트리거된다. "선형변환 개념의 기억 파지율이 90% 이하로 하강하고 있습니다. 2분 플래시 퀴즈로 지식을 고정하세요"와 같이 인지 상태와 직결된 알림을 제공함으로써 학습 동기를 극대화한다.

7. 서비스 상용화 제약 요인과 운영 비용 최적화 및 비즈니스 모델

7.1 YouTube 및 외부 플랫폼 API 이용약관(ToS) 규제 준수

대다수의 글로벌 및 국내 공개 강좌가 YouTube 인프라를 매개로 비디오를 스트리밍하고 있으므로, 상용 앱 배포 시 Google의 개발자 정책(YouTube Developer Policies)을 철저히 준수해야 한다. 규정 위반 시 API 키 박탈 및 앱스토어 서비스 차단 등의 법적·사업적 제재가 부과된다.

무엇보다 YouTube API 이용약관은 영상 플레이어가 사용자 화면에 노출되지 않는 상태, 즉 화면 잠금, 백그라운드 전환, 타 앱 전환 시 오디오만을 분리하여 재생하는 행위를 엄격히 금지하고 있다. 따라서 오디오 전용 팟캐스트 모드는 플랫폼 자체 호스팅 음성 파일에 한해서만 제공될 수 있으며, 유튜브 기반 강의에 대해서는 화면이 커져 있는 인앱 활성 뷰포트 상태에서만 재생을 허용해야 한다. 또한 유튜브 비디오에서 오디오 트랙을 별도로 분리 추출(Rip)하거나 로컬 디스크에 무단 다운로드하여 오프라인으로 재생하는 행위 역시 명시적으로 금지된다. 마지막으로 공식 Iframe 플레이어의 기본 컨트롤러나 워터마크를 임의로 가리거나 원본 영상에 삽입된 광고의 송출을 차단하는 UI 변형은 전면 불허되므로, 튜터링 인터페이스는 플레이어의 조작 영역과 겹치지 않는 독립적인 분할 뷰포트에 렌더링되어야 한다.

7.2 추론 비용 절감을 위한 계층적 캐싱 및 모델 캐스케이딩

실시간 대화형 튜터링 서비스는 학생 1인당 대규모 입출력 토큰을 유발하므로, 단위 경제성(Unit Economics)을 확보하지 못하면 서비스 확장이 불가능하다. 이를 해결하기 위해 시스템은 3단계 비용 최적화 파이프라인을 운영한다.

가장 먼저 인메모리 벡터 저장소를 활용한 시맨틱 캐싱(Semantic Caching)을 게이트웨이에 배치한다. 사용자의 질문이 과거 다른 학습자가 질의했던 질문과 임베딩 코사인 유사도 0.96 이상으로 일치하는 표준적 개념 문의일 경우, 고비용 LLM을 호출하지 않고 기검증된 소크라테스 유도 템플릿을 즉시 반환하여 응답 지연과 비용을 동시에 제거한다.

캐시 미스가 발생한 경우 요청은 모델 캐스케이딩(Model Cascading) 라우터로 전달된다. 단순 객관식 퀴즈 채점, 학습 진도 추적, 어휘 정의 확인과 같은 저난도 작업은 비용이 저렴한 8B급 소형 언어 모델(SLM)로 처리하고, 복잡한 증명이나 심화 소크라테스 문답에 한해서만 32B 이상의 대형 추론 모델로 라우팅한다.

마지막으로 고성능 모델 호출 시에는 시스템 프롬프트 및 온톨로지 메타데이터에 대한 프롬프트 캐싱(Prompt Caching)을 강제 적용한다. 수천 토큰에 달하는 대학 강좌의 강의계획서와 지식 그래프 토폴로지 정보를 컨텍스트 프리픽스로 고정하고 캐시 히트를 유도함으로써, 입력 토큰 처리 비용을 최대 90%까지 절감할 수 있다.

7.3 지속 가능한 상용화 비즈니스 모델(BM)

공개 강좌의 비영리 라이선스(CC BY-NC-SA)를 침해하지 않으면서 안정적인 수익성을 확보하기 위해 다각화된 비즈니스 모델을 병행 전개한다.

사업 모델 분류	주요 목표 고객군	수익 창출 메커니즘	지식재산권 리스크 방어 논리
Freemium BYOC SaaS	대학 재학생 및 자격증 독학자	강좌 검색, 기본 로드맵, 기본 영상 재생은 무료 제공. 무제한 소크라테스 AI 대화, FSRs 무제한 오답 관리, 실시간 수식	강의 콘텐츠 자체는 무료이며, 사용자가 연동한 자료에 부가되는 'AI 연산 및 인지 학습 도구 사용료'로 정의.

사업 모델 분류	주요 목표 고객군	수익 창출 메커니즘	지식재산권 리스크 방어 논리
		검증에 월 구독료 과금.	
B2B / B2U 대학 연계 SaaS	고등교육기관, 사이버대학, 평생교육원	대학 학습 관리 시스템(LMS)과 LTI(Learning Tools Interoperability) 표준으로 연동되는 인공지능 교수 보조 교료 라이선스 판매.	대학이 보유한 정규 교과목 자체 저작권을 활용하므로 외부 오픈 라이선스 충돌 위험 원천 배제.
마이크로 자격증 인증 수수료	직무 전환 및 전문 기술 습득 희망자	공인 파트너십 기관의 커리큘럼 완료 시 블록체인 및 Open Badges 기반의 검증된 역량 인증서 발급 수수료 부과.	학습 및 지식 습득 과정은 무상으로 개방하되 역량 평가 및 공식 자격 검증 절차에 한해 비용 부과.

8. 결론

공개 대학 강의 및 오픈 코스웨어 생태계는 고등 지식의 대중화라는 획기적인 성과를 거두었음에도 불구하고, 방대한 분량의 비구조화된 미디어와 상호작용의 부재로 인해 자기주도적 완주가 극히 어렵다는 한계가 지속되어 왔다. 본 연구에서 제안한 시스템은 Whisper와 ColPali 기반의 멀티모달 RAG 파이프라인과 다기준 투표 기반의 교육용 지식 그래프(EduKG)를 결합하여 대학 강의의 시공간적 맥락을 정밀하게 구조화한다. 이를 바탕으로 계층적 다중 에이전트 시스템(MAS)을 가동하여 학습자의 선수 지식 결손을 실시간으로 메우는 동적 커리큘럼을 편성하고, 소크라테스식 문답법과 Python SymPy 기호 연산 검증을 결합하여 환각 없는 1:1 튜터링을 구현한다. 나아가 DSR 기반의 FSRs 스케줄러를 LMS의 코어로 배치함으로써 복습 효율을 20~30% 개선하고 장기 기억 형성을 뒷받침한다. 법률적으로는 YouTube API 정책과 CC BY-NC-SA 제약을 철저히 준수하는 BYOC 아키텍처를 확립하고 프롬프트 캐싱을 통한 토큰 비용 절감을 실현함으로써, 공공 지식 자산의 가치를 극대화하는 차세대 모바일 에듀테크 서비스의 실현 가능성을 제시한다.

참고 자료

1. [44호] 코스모스 인사이트 - 우리는 왜 공유(Open)하게 됐을까?, <https://support.coursemos.kr/ko/channel/insight/view/338> 2. 온라인 대학 강좌(강의) OCW, MOOC가 한국에?? - 류 학생 블로그, <https://jobsrunblog.tistory.com/3> 3. OCW - 나무위키, <https://namu.wiki/w/OCW> 4. LLM-Assisted Knowledge Graph Completion for Curriculum ... - arXiv, <https://arxiv.org/html/2501.12300v1> 5. Educational Knowledge Graph Creation and Augmentation via LLMs, https://www.researchgate.net/publication/381064455_Educational_Knowledge_Graph_Creation_and_Augmentation_via_LLMs 6. FAQ: Intellectual Property | MIT OpenCourseWare, <https://opencw.aprende.org/help/faq-intellectual-property/> 7. | K-MOOC, <https://www.kmooc.kr/> 8. K-MOOC - 나무위키:대문, <https://namu.wiki/w/K-MOOC> 9. K-Mooc 강의 목록 - 삼육대학교, <https://www.syu.ac.kr/curriculum/lecture-list-of-kmooc/> 10. 공공데이터 제공 대체 사이트, <https://velog.io/@youngkiu/%EA%B3%B5%EA%B3%B5%EB%8D%B0%EC%9D%B4%ED%84%B0-%EC%A0%9C%EA%B3%B5-%EB%8C%80%EC%B2%B4-%EC%82%AC%EC%9D%B4%ED%8A%B8-xssfysco> 11. KERIS, KOCW로 대학 원격수업 지원 - 전자신문,

<https://m.etnews.com/20200304000189?obj=Tzo4OiJzdGRDbGFzcyl6Mjp7czo3OiJyZWZlcmVyIjtOO3M6NzoiZm9yd2FyZCI7czoxMzoid2ViHRvIG1vYmlsZSI7fQ%3D%3D> 12. How do I use MIT OpenCourseWare (OCW)?, <https://support.learn.mit.edu/hc/en-us/articles/42900796765083-How-do-I-use-MIT-OpenCourseWare-OCW> 13. 저작권가이드 - KOCW - 서비스도움말, <https://www.kocw.net/home/m/guide/copyrightList.do> 14. How is "all rights reserved" content different from the rest of OCW, <https://mitocw.zendesk.com/hc/en-us/articles/4414756181403-How-is-all-rights-reserved-content-different-from-the-rest-of-OCW-content> 15. Privacy and Terms of Use | MIT OpenCourseWare, <https://ocw.mit.edu/pages/privacy-and-terms-of-use/> 16. [대법원] 저작권법위반 유튜브 설교 영상 무단 게시가 정당한 인용에, <https://www.copyright.or.kr/information-materials/trend/precedents/view.do?brdctsno=54566> 17. 온라인 링크, 공유만 해도 저작권 침해가 될 수 있나요? - 토스페이먼츠, <https://www.tosspayments.com/blog/articles/legal2-5> 18. Complying with YouTube's Developer Policies, <https://developers.google.com/youtube/terms/developer-policies-guide> 19. Terms of Service - YouTube, <https://www.youtube.com/static?gl=KR&template=terms> 20. ColPali and Multimodal Document RAG on GPU Cloud, <https://www.spheron.network/blog/colpali-multimodal-document-rag-gpu-cloud/> 21. Chapter 3: Multimodal RAG - Medium, <https://medium.com/@marcharaoui/chapter-3-multimodal-rag-e3fdd9b3e450> 22. Multimodal RAG: Retrieval-Augmented Generation for ... - Mixpeek, <https://mixpeek.com/multimodal-rag> 23. How We Built Multimodal RAG for Audio and Video - Ragie.ai, <https://www.ragie.ai/blog/how-we-built-multimodal-rag-for-audio-and-video> 24. Video-RAC: Retrieval Adaptive Chunking for Lecture Video RAG, <https://prismaticlab.github.io/Video-RAC/> 25. Inferring Prerequisite Knowledge Concepts in Educational ... - arXiv, <https://arxiv.org/pdf/2509.05393> 26. CodeEdu: A Multi-Agent Collaborative Platform for Personalized, <https://arxiv.org/pdf/2507.13814> 27. CURRICULUM GUIDED MASSIVE MULTI AGENT SYSTEM ... - arXiv, <https://arxiv.org/pdf/2512.08545> 28. [2606.18633] PersonalPlan: Planning Multi-Agent Systems ... - arXiv, <https://arxiv.org/abs/2606.18633> 29. Agent-Oriented Planning in Multi-Agent Systems - arXiv, <https://arxiv.org/pdf/2410.02189> 30. Agent-Oriented Planning in Multi-Agent Systems - OpenReview, <https://openreview.net/forum?id=EqcLAU6gyU> 31. What Is Explain My Answer In Duolingo Max? Feature Overview, <https://duolingoguides.com/what-is-explain-my-answer-in-duolingo-max/> 32. K12-KGraph: A Curriculum-Aligned Knowledge Graph for ... - arXiv, <https://arxiv.org/html/2605.09635v1> 33. The system prompt for Khanmigo Lite - GitHub Gist, <https://gist.github.com/25yeht/c940f47e8658912fc185595c8903d1ec> 34. Khanmigo vs Socratic by Google: Which Is Better for Teachers?, <https://www.edugenius.app/blog/khanmigo-vs-socratic-by-google-which-is-better-for-teachers> 35. An Easy Introduction to Multimodal Retrieval-Augmented Generation, <https://developer.nvidia.com/blog/an-easy-introduction-to-multimodal-retrieval-augmented-generation-for-video-and-audio/> 36. How Duolingo Uses ML Pipelines to Personalize Learning for 50M+, <https://www.techaheadcorp.com/blog/how-duolingo-personalizes-learning/> 37. Building Speak's Voice Agent Platform, <https://www.speak.com/blog/building-speaks-voice-agent-platform> 38. Speak: Language Learning - Apps on Google Play, <https://play.google.com/store/apps/details?id=com.selabs.speak> 39. Best AI Socratic Tutoring Platforms, According to ChatGPT & Google AI, <https://parse.gl/markets/tutoring/ai-socratic-tutoring-platforms> 40. Introducing Duolingo Max, a

learning experience powered by GPT-4, <https://blog.duolingo.com/duolingo-max/> 41. Duolingo Max (Product Review) - MAA1 - Medium, <https://maa1.medium.com/duolingo-max-product-review-26d71981f4cf> 42. Duolingo's AI Strategy Fuels 51% User Growth and \$1B Revenue, <https://chiefaiofficer.com/duolingos-ai-strategy-fuels-51-user-growth-and-1b-revenue/> 43. Speak for Android - Download the APK from Uptodown, <https://com-selabs-speak.en.uptodown.com/android> 44. Speak is personalizing language learning with AI - OpenAI, <https://openai.com/index/speak-connor-zwick/> 45. An Alternative Chat UI Layout - LukeW Ideation + Design, <https://www.lukew.com/ff/2135/an-alternative-chat-ui-layout> 46. VidGen - AI Video Generation & UX UI Design - Rondesignlab, <https://rondesignlab.com/cases/vidgen-ai-video-creation-ux-ui-design> 47. FSRS Algorithm - Grafoxi, <https://grafoxi.com/fsrs/> 48. What Is FSRS? The Smartest Spaced Repetition Algorithm - MintDeck, <https://www.mintdeck.app/blog/fsrs-spaced-repetition-algorithm> 49. FSRS (Free Spaced Repetition Scheduler) — Study Science Glossary, <https://revu.cards/glossary/fsrs> 50. Free Spaced Repetition Scheduler algorithm - GitHub, <https://github.com/open-spaced-repetition/free-spaced-repetition-scheduler> 51. FSRS Projects - AI Tinkerers, <https://aitinkerers.org/technologies/fsrs> 52. 해외 OCW 사이트 - KOCW, <https://www.kocw.net/home/special/om.do?t=FO> 53. YouTube API Services Terms of Service - Google for Developers, <https://developers.google.com/youtube/terms/api-services-terms-of-service> 54. YouTube API Services - Developer Policies, <https://developers.google.com/youtube/terms/developer-policies> 55. Background play isn't working - Android - YouTube Help, <https://support.google.com/youtube/answer/7437614?hl=en&co=GENIE.Platform%3DAndroid> 56. Prompt Caching breakdown: Cut token spend in 2026 - Flexera, <https://www.flexera.com/blog/ai/prompt-caching-breakdown/>